Automatic Prompt Engineering Strategy

Viska Wei

Agenda

1. 背景介绍 - Why AutoPE？
2. 现有技术 - Badcase Strategy有哪些优化空间？
3. 优化策略 - Margin Strategy，Preference Trace Strategy
4. 策略实现 - ark_navigator/viska-strategy branch代码解析
5. 总结

Why AutoPE？

1. **敏感&误解:** LM对提示格式, 顺序敏感, 会误解有歧义的表述
   a. 即使微小的变化也会显著影响其性能 (Zhao et al., 2021; Lu et al., 2021; Wei et al., 2023; Madaan & Yazdanbakhsh, 2022)
   b. 语义相似的提示，不同顺序数量的例子有巨大性能差 (Kojima et al., 2022; Zhou et al., 2022b; Zhang et al., 2023)
2. **耗时耗力:** 创造生产级提示（黄金答案）需大量人力物力与LLM调用
3. **基座模型不断 变化:** 无时间维度上的最优策略

Insight: 最佳提示可能是特定于模型和具体任务(user prompt)的(Ma et al., 2023; Chen-2307.09009; Deng-2311.04205; Hao-).

Badcase有哪些优化空间？

（1）目前时间和调用次数5-5-3限制下 (badcase 5+3)x 5=40

1. 优化效果差，提示词几乎不变
2. Analyzer, Summarizer, Optimizer, Generalizer对于分类问题过于臃肿，达到最优需要～(badcase10 + 3) x 20 = 260

解决方法 → Margin Strategy（O((5+1) x 5)=30 达到最优）

（2）出现退化

1. 找到最优解的路径过于曲折
2. 对尝试过的提示词无记忆

解决方法 → Preference Trace Strategy

1. 速度慢：～40次LLM调用下的提示词几乎不变：

【综合情况】

优化后正确率：96.50%，优化后badcase数：7
初始的正确率：96.50%，初始的badcase数：7

【优化prompt】

请判断你是否需要借助搜索引擎来回答下面的问题，只回答需要或不需要。
问题：{{user_prompt}}
输出：

【初始prompt】

请判断你是否需要借助搜索引擎来回答下面的问题，只回答需要或不需要。
问题：{{user_prompt}}
输出：

【优化prompt】

你是一个插件意图识别机器人，请根据用户问题准确分析潜在意图类别（weather, car, news, video, other）。意图类别解释如下：
weather：明确与天气状况（温度、天气类型、季节与穿衣等）相关的咨询
car：关于车辆的各类咨询，如车辆性能、购买、保养等
news：有关各类新闻的询问
video：涉及视频的搜索、推荐等相关咨询
other：无法明确归入以上类别的咨询
请直接回答具体类别，不要回答其他内容。

用户输入如下：{{user_prompt}}
输出：

【初始prompt】

你是一个插件意图识别机器人，请根据用户问题分析潜在意图类别（weather, car, news, video, other）。意图类别解释如下：
weather： 咨询天气相关问题
car：咨询车辆相关问题
news： 咨询新闻问题
video： 咨询视频相关问题
other： 咨询其他问题
请直接回答具体类别，不要回答其他内容。

用户输入如下：{{user_prompt}}
输出：

【综合情况】

优化后正确率：77.78%，优化后badcase数：16
初始的正确率：73.61%，初始的badcase数：19

调用40次生产的优化：
效果有，但不显著

【优化prompt】

现在您是到综行业服务标签分类器，有人工客服与消费者的对话信息，记录在#session-begin #session-end之间；S代表人工客服，U代表消费者。请根据对话信息，准确判断该对话所属的三级服务标签，结果按照json格式输出，key的集合为{"三级服务标签"}，“三级服务标签”的取值范围为["不承认团购活动"，"订单被多核销/错核销/提前核销"，"暂停营业无法接待"，"服务类效果不达预期（主观）"，"额外增加或变更使用条件"，"个人原因申请退款"，"咨询商品信息及使用规则"，"咨询退款规则及方法"，"缺货或人力不足"，"商家要求加价"，"无法预约/改约"]，取值结果唯一，不要输出冗余信息。

在判断服务标签时，需重点关注消费者与客服的沟通内容，明确消费者的核心诉求和问题所在。例如，若消费者表示商家不承认团购活动，则服务标签为“不承认团购活动”；若消费者因商家变更使用条件而产生不满，则服务标签为“额外增加或变更使用条件”；若消费者反映订单自动取消导致无法购买，应判断为“缺货或人力不足”。

示例：
#session-begin
S:您好，请问需要什么帮助呢。S:这边查询您的历史记录，是您的券还未用完商家闭店了对吗。U:希望你们帮我退款。U:对的。S:辛苦稍等一到三分钟，这边帮您了解一下。S:您看您愿意提供您的联系方式并给到商家吗[送心]。U:可以。S:好的，辛苦您提供一下您的联系方式呢[送心]。S:好的。S:您好，您的情况这边转接抖音专员为您处理，预计24小时给到您回复您看可以吗。S:这边是刚刚联系您的客服，这边为您转接专员了，预计24小时内会给到您回复的[送心]。
#session-end
判断结果是：
{"三级服务标签": "暂停营业无法接待"}

回答下面问题：

方法:让LLM为每个分类生产细化描述，划清每条类别界限

个人原因申请退款：

服务类效果不达预期：

额外增加或变更使用条件：

缺货或人力不足：

商家要求加价：

LLM生成

个人原因申请退款：

必须有明确的用户主观不想用或未使用的表述，如"我就是不想要了""突然不想用了""未使用但想退款"等。同时，要排除客服不理及不退款等情况。不可将所有退款问题默认为个人原因申请退款，必须要有明确的用户主观表述且无其他问题才能归类为此类别。区分要点在于个人原因是消费者自身的主观意愿，而非其他外部因素导致。

服务类效果不达预期：

涵盖电玩城、美容院等场所服务未达标或商品与订单不符，例如服务质量差、效果未达到预期、商品与描述不符、服务环境差等，相关关键词包括"效果差""质量不行""订单和消费不符"等；要特别注意用户对服务效果的明确不满表述。

额外增加或变更使用条件：

涉及预约或改约等规则变动，像突然增加费用、更改预约时间、未预约直接到店不给做等；留意规则变动的具体情况。

无法预约/改约或因系统故障或商家限制，比如系统出错无法预约、商家规定不能改约等；关注是系统还是商家的原因导致。

缺货或人力不足：

关乎商品缺货或服务人员短缺，像商品库存不足、服务人员不够等；准确判断是缺货还是人力问题。

商家要求加价：....

Margin Strategy

针对分类的**规则挖掘**策略

旨在划清类别边界

流程图

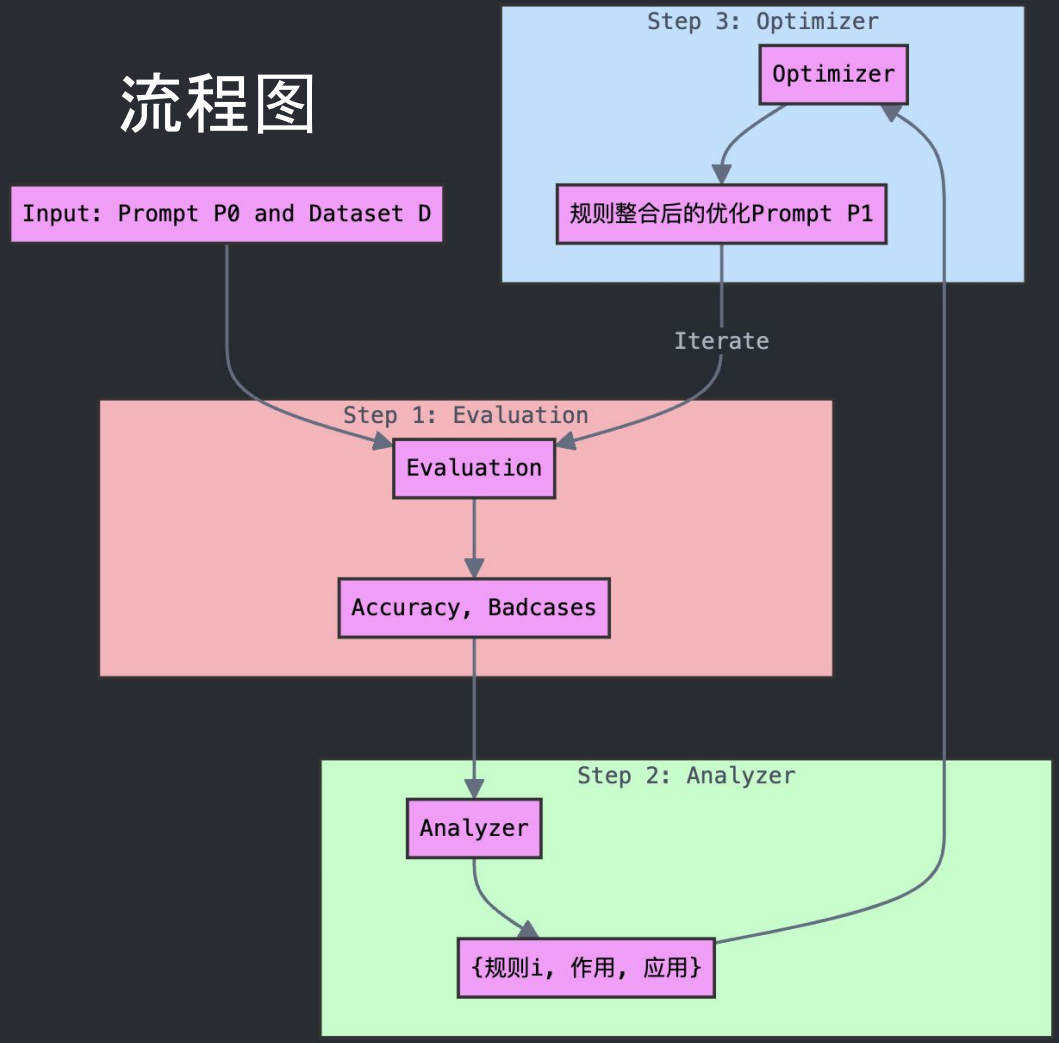

Analyzer

角色：你是一位精通分类规则挖掘与优化的AI专家，擅长分析边界案例，量化标准，并提炼出精确、一致的分类规则。

步骤1：Ground Truth规则总结

- 提取隐含在Ground Truth中的分类规则
- 为每条规则添加解释，说明其在分类过程中的作用

步骤2：Badcase规则分析

- 识别模型回答中缺失或违反的关键规则
- 指出模型回答中可能存在的错误理解或应用

步骤3：规则优化

- 基于步骤1，2的分析结果，修改、补充或重新制定分类规则

确保新规则能够解决模型回答中的问题，并提高分类准确性

#输出

规则1：[明确、具体的规则描述]

作用：[解释这条规则如何改善分类准确性]

应用：[具体说明如何在分类过程中应用这条规则]

Optimizer

角色：你是一位精通将多个badcase总结出的规则进行整合分析并制定最终明确规则的AI专家

步骤1：规则整合

- 汇总所有badcase中提取的新规则
- 将新规则与原始prompt中的规则进行比较
- 合并相似或重复的规则，解决潜在的冲突

步骤2：反思规则合理性

- 检查每条规则是否符合逻辑
- 考虑规则是否可能导致新的错误分类
- 评估规则的普适性和特殊性

步骤3：输出新规则集

- 基于前两步的分析和评估，制定一套新的、优化过的规则
- 确保每条新规则清晰、准确，并易于理解和执行

#输出：优化后的Prompt

结果: 细节见PE-log

- 更少调用LLM　O(10) vs O(50) + detail
- 更快找到最优（无summarizer, Generalizer）

Huayi在metallm中已有类似feature，效果显著

- 请问下列标签增加更细化的规则描述：

18吉利插件：豆包96->98.7（6-iter）GPT 100->100（11-iter）

32抖音酒旅：豆包__->79（3-iter）GPT 80->79（6-iter）

33抖音服务：豆包70->76（10-iter GPT 80->84（7-iter）

54番茄销售：豆包86->94（1-iter）GPT 94->96（2-iter）

72奈特瑞. ：豆包__-> 82*（5-iter）GPT 82->86（8-iter）

Margin Prompt++: 规则挖掘+细化标签描述+边界正反案例

Analyzer

角色

你是一位精通分类系统优化的AI专家，擅长对错误案例进行分析，提炼出精确、一致的类别描述，并善于将规则整合到描述中以定义清晰的类别边界。

分析步骤

请按照以下步骤进行分析：

1. 参考答案类别特征和规则提取
   - 仔细分析参考答案，提取关键类别特征和隐含规则
   - 识别这些特征和规则如何定义类别的核心含义和边界
2. 错误模型回答分析
   - 识别模型回答中对类别的误解或错误应用
   - 指出模型回答中存在的类别边界模糊问题
   - 分析导致错误的潜在原因（如特征理解不清、边界模糊等）
3. 类别描述优化与规则整合
   - 基于步骤1和2的分析结果，创建一个综合的类别描述
   - 将提取的规则自然地整合到描述中，确保描述既全面又简洁
   - 明确定义类别边界，减少与其他类别的重叠或混淆
4. 边界案例识别
   - 基于优化后的描述，识别关键的边界案例
   - 提供明确的正面和负面示例，特别是容易混淆的边界情况

优化后的类别描述

类别名称：[原始类别名称]

整合描述：[详细、精确的类别描述，包含以下元素：]

- 类别的核心定义
- **关键特征和规则，自然地融入描述中**
- 类别的适用范围和限制条件
- 与其他相近类别的区别
- 分类时的注意事项，包括常见的误判情况和处理方法

应用示例：

- 正面示例：
  1. [**明确属于** 该类别的案例，解释为什么属于]
  2. [**边界但仍属于** 该类别的案例，解释判断依据]
- 负面示例：
  1. [**明确不属于** 该类别的案例，解释为什么不属于]
  2. [**边界但不属于** 该类别的案例，解释判断依据]

输出要求

- 确保描述全面、连贯，同时包含所有必要的规则和特征
- 描述应清晰展示如何判断一个案例是否属于该类别
- 优化后的描述应能有效解决分析中发现的问题，提高分类准确性
- 边界案例应该清晰展示类别的界限，帮助理解类别的适用范围
- 整体输出应简洁明了，便于实际应用和理解

Margin Prompt++ Analyzer 输出:

步骤1:GT类别特征和规则提取... #步骤2:错误模型回答分析...# 步骤3:类别描述优化与规则整合

类别名称: **服务类效果不达预期（主观）**

整合描述: 该类别包含所有涉及服务效果未达到消费者预期的情况，如服务质量差、服务效果未达标、商品与订单不符等。关键是用户对服务效果的明确不满表述。在判断时，应主要关注消费者对服务或商品效果的直接反馈，而非其他外部因素。

 # 步骤4:边界案例识别

正面示例:

1. "我买的是洗发水，但用完之后头发变得更油了，这明显不是我想要的效果。"（属于，因为用户对商品效果明确表示不满）
2. "我预约的美容服务，但效果一点都不好，我想退款。"（虽然涉及预约服务，但主要问题是服务效果不佳，不是"无法预约/改约"因此属于）

负面示例:

1. "我买了一瓶洗发水，但快递寄丢了。"（不属于，因为问题在于快递服务，而非洗发水的效果）
2. "我预约了美容服务，但到店要加价，我想退款。"（虽然涉及预约服务，原因是"**商家要求加价**"，不是服务效果，因此不属于）

效果Prompt最优：

局限性：数据差，提取到错误规则难回头

举例：

UP: 滴滴情绪 - 滴滴司机差劲！！！！！！！！

<u>提取的错误规则</u>：重复使用特殊符号>6次则为负面

解决方法：

1. 加强反思机制，结合SP思考新添加规则是否正确
2. 人机交互，剔出错误数据，生成具有挑战的边界case**让人来标**（AutoPrompt）

2. 退化现象：越跑越差

主要原因分析：无错题集

头铁：每次badcase都是从当前最优解p’开始优化导致：

1. 不能从失败中吸取经验。
2. 卡在local optimal, 一旦走错无法backtrack
    a. 为什么是local optimal？确实提供了分类信息
    b. 为什么会trap？ 卡在特定格式里，但 该格式未对齐LLM偏好

解决方法：提供优化轨迹 - { (正确率，Prompt) }

AutoPE优化轨迹回流策略是一种用于提示词优化的方法，由提示词优化大师执行。它通过分析高低正确率提示词的特征，构建新的、独特的提示词。该策略利用历史数据和性能分析，系统性地改进提示词

旨在持续提高性能，特别适用于需要精细调整的复杂任务或特定领域应用。

新提示词需要与现有提示不同，遵循错误分析建议，修复失败因素，并争取更高得分。

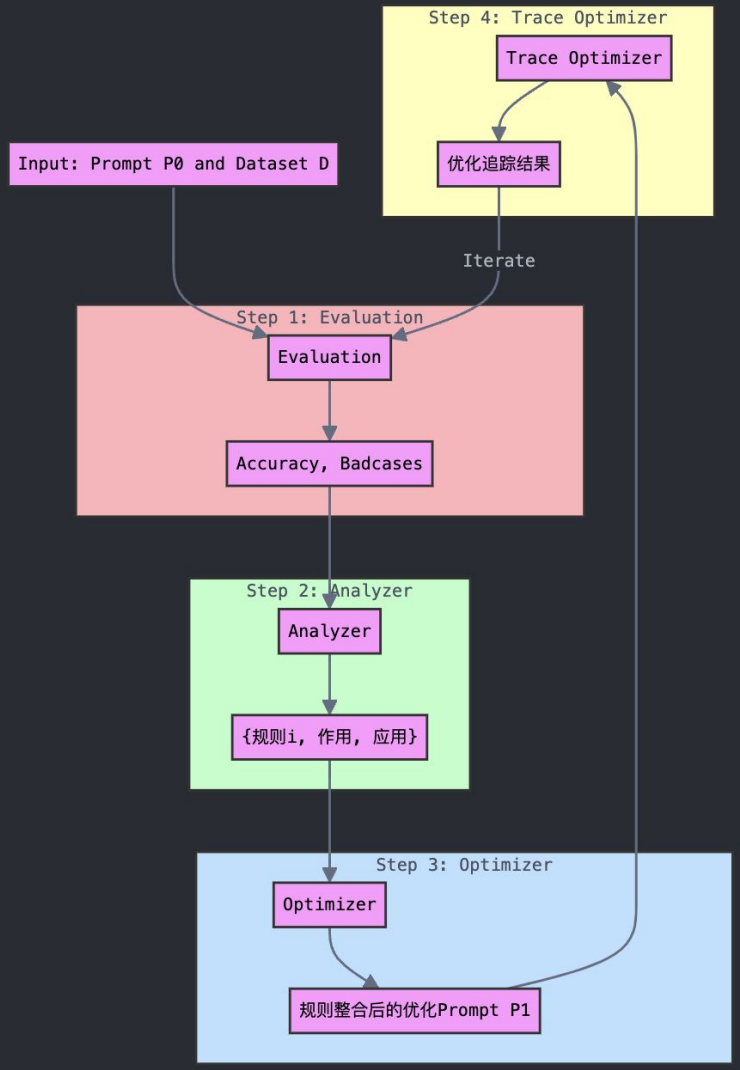

Prompt with Preference Trace

Trace Optimizer

角色：你是一个提示词优化大师，擅长对一个具体领域或场景的提示词做出改进。

输入： {prompt trace}

步骤1： 分析现有prompt trace

- 分析你现有的prompt和它们对应的正确率。尝试找出正确率高的prompt有哪些共同点。这些共同点可能是使用特定的关键词、语句结构、详细程度等。
- 分析那些正确率低的prompt，看看它们是否有一些常见的问题，比如模糊不清的表述、缺乏具体信息等。

步骤2： 生成新提示词

- 基于你的分析结果，构建一个包含高正确率prompt特征的新prompt。确保新的prompt避免了之前低正确率prompt的问题。例如，如果你发现具体和详细的prompt表现更好，确保你的新prompt包含足够的详细信息和具体描述。

新的提示需（1）与上面所有提示不同（2）完全遵循错误分析修改建议，并修复提示以防止失败情况。（3）比上述所有提示得分更高。

目前结果一般，需进一步研究。

主要问题：

1. 怎么冷启动？
2. Prompt输入太长怎么解决？
3. 如何往正确路径上引导？

ark_navigator/viska-strategy branch代码解析

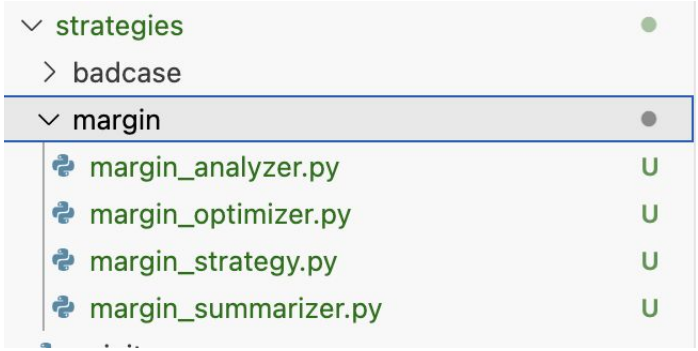


```
# templates/prompts_margin.py
analyzer:
# 角色：你是一位精通分类规则挖掘与优化的AI专家，擅长分析边界案例，量化标准，并提炼出精确、一致的分类规则。...
步骤1：参考答案规则提取 - 仔细分析参考答案的内容...
步骤2：模型回答规则分析：...
步骤3：规则优化建议：...
Optimizer:
# 角色：你是一位精通将分类分析结果转化为明确规则的AI专家，擅长提炼和更新分类prompt。
# 任务：基于前述分类优化流程的输出，总结新的分类规则并更新到原始prompt中。
1. 规则提取 ….
2. 规则整合 ….
3. Prompt优化 ….
   - 在原始prompt的适当位置插入新的规则
   - 调整原有的表述以适应新规则
```

```
# ark_navigator/ape/strategies/strategy_router.py 内手动开启
def route(self, prompt='prompt', task_description='task_description', domain='domain', task_type='task_type'):
        # return BadcaseStrategy  # we only have BadcaseStrategy for now
        return MarginStrategy
```

Preference Trace

```
#new ape_driver
def gen_trace(self, prompt_acc_list):
        """Generate the meta-prompt for optimization.
        Args:
        prompt_acc_list (list): the set of (acc, prompt) pairs.
        max_num_trace (int): the maximum number of exemplars in the meta-prompt.
        Returns:
        meta_prompt (str): the generated meta-prompt.
        """
        trace = ""
        for i, (acc_i, prompt_i) in enumerate(prompt_acc_list):
            trace += f"({i}): 正确率：{acc_i},提示词：{prompt_i}\n\n"
        print(trace)
        return trace
```

Thanks

其他策略

其他策略:

Pruning策略: 依次删去最无关/最差的选项

假设： LLM去除无关/干扰信息后，正确率会增加 （需验证）

应用： 动作空间 $A = \{a^k\}$ 较大的case; 需要从一系列选项中选择最优

限制： 确定“最差”选项的准则必须清晰，避免因定义不明导致剪枝结果不准确

Pseudo-code (vanilla):

for e=1 to Epochs do

Initialization: p_0 is the best pruning prompt

Feedback/badcase Optimization: 前馈：

Forward: Prune $a_i^k = f([q_i, A_i]; p_0)$ 从动作空间 A_i 内选择最差的选项 a_i^k 减枝

Backward： 后馈：

Feedback: $b_i = f([p_0, q_i, A_i, a_i^k, a^*]; c_{fb})$ 反馈是否剪错（减掉了标准答案 a^* ）： $a_i^k = a^*$

$p_1 = f([p_0, \{b_i\}_{i=1}^k]; c_g)$ 通过prune错的例子总结经验，更新prompt:p0 -> p1

偏好提示策略

[APEER: Automatic Prompt Engineering Enhances Large Language Model Reranking]

APEER通过反馈和偏好优化来改进提示，从而提高LLM的重排rerank能力。

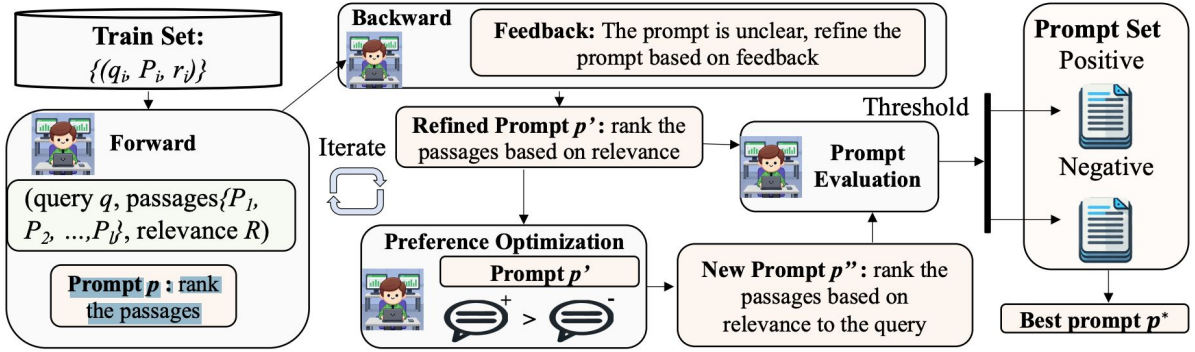

Algorithm 1 APEER

Input: LLM f, Training Dataset $\mathcal{D}_{train} = \{(q_i, \mathcal{P}_i, r_i)\}_{i=1}^{n}$, Validation Dataset $\mathcal{D}_{val} = \{(q_i, \mathcal{P}_i, r_i)\}_{i=1}^{m}$, $p = p_{init} = p_{pos}$, Positive Prompts History $\mathcal{H}_{pos} = \{p_{pos}\}$, Negative Prompts History $\mathcal{H}_{neg} = \{p_{neg}\}$, Meta Prompts c_{fb}, c_g, c_{pre}.

for $e = 1$ to Epochs **do**

  Sample a batch of data $\mathcal{B} \subset \mathcal{D}_{train}$

  Initialization: p is best prompt in $\mathcal{H}_{pos}$

  Feedback Optimization:

    Forward: Response $s_i = f([q_i, \mathcal{P}_i]; p)$

    Backward:

      Feedback $b_i = f([p, q_i, \mathcal{P}_i, s_i, r_i]; c_{fb})$

      $p' = f([p, \{b_i\}_{i=1}^{k}]; c_g)$

  Evaluate and add p' to $\mathcal{H}_{pos}$ or $\mathcal{H}_{neg}$

  Preference Optimization:

    $p'' = f([p', \{(p_{pos}, p_{neg})\}]; c_{pre})$

  Evaluate and add p'' to $\mathcal{H}_{pos}$ or $\mathcal{H}_{neg}$

end for

return The best prompt $p^* \in \mathcal{H}_{pos}$

后续调研

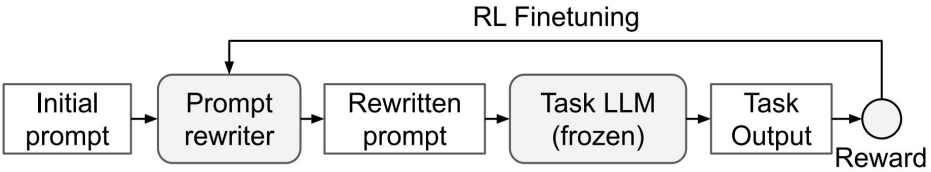

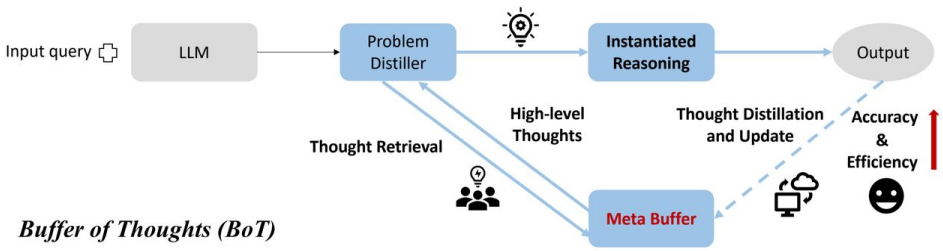

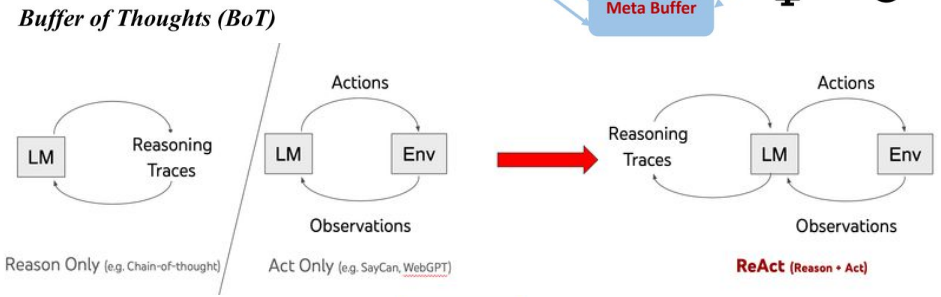

What's next?

1. Human-in-Loop
2. Tools (RL-in-Loop)
3. Memory, Reason, Planning

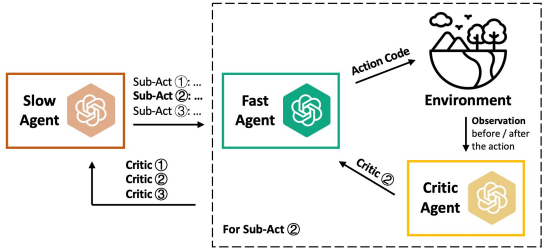

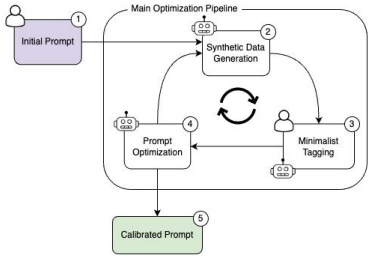

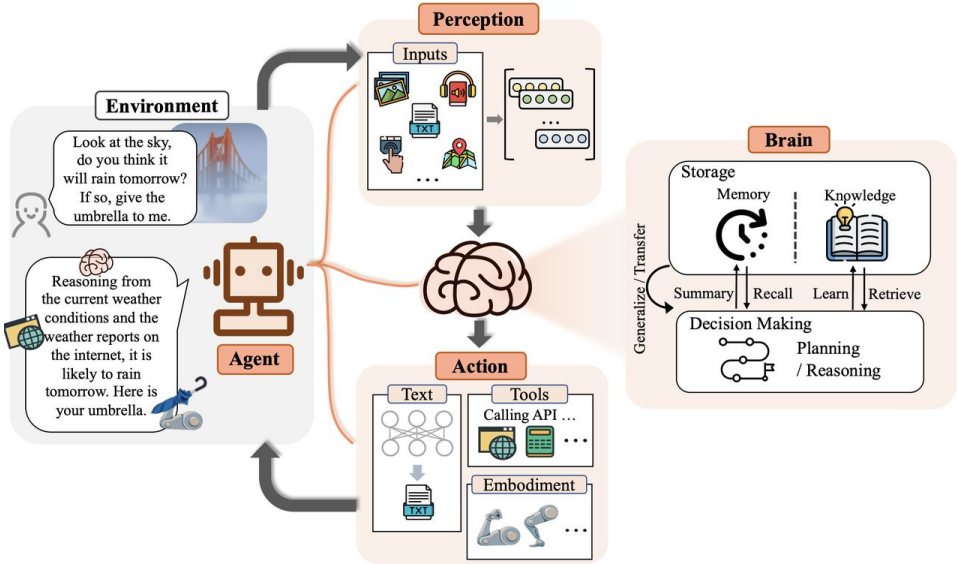

Human-in-Loop

[Elad Levi on AutoPrompt and intent-based prompt calibration and prompt engineering](#)（Github）

AutoPrompt是一个实现基于意图校准提示的框架，通过迭代构建最具挑战的边界案例并由人标识来优化提示。

用户输入：用户提供初始提示和任务描述来启动校准

数据增强：基于当前prompt生成有挑战的边界案例

人机交互标识：标注挑战案例（只需～20个例子）

优化：（1）使用当前提示对注释样本进行评估，以评估模型性能。（2）分析识别badcase（3）提出新Prompt

迭代：步骤234重复至收敛，在过程中完善提示并增强模型的性能。

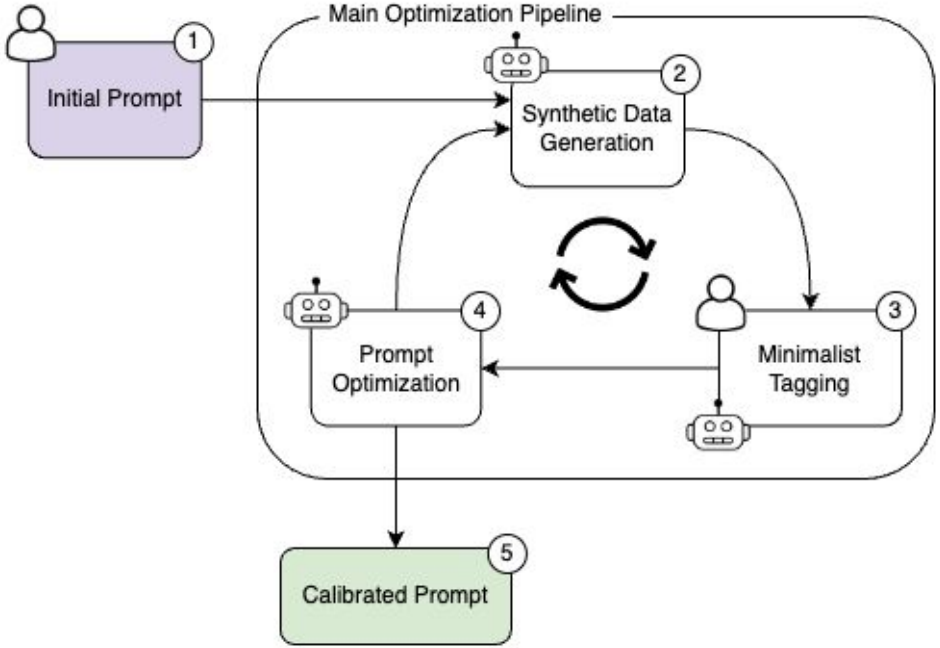

RL-in-Loop

RL-GPT：思考，快与慢， Minecraft SOTA

[RL-GPT: Integrating Reinforcement Learning and Code-as-policy]

RL-GPT是一个快慢两级分层框架用于增强LLM从环境互动中学习的能力。慢代理分解任 务并思考规划哪些子任务需要RL学习，哪些由快代理直接 编码解决。

将LLM与RL结合，提升复 杂环境中任务执行的效率

将RL作为工具来克服LLMs在低层控制中的不足

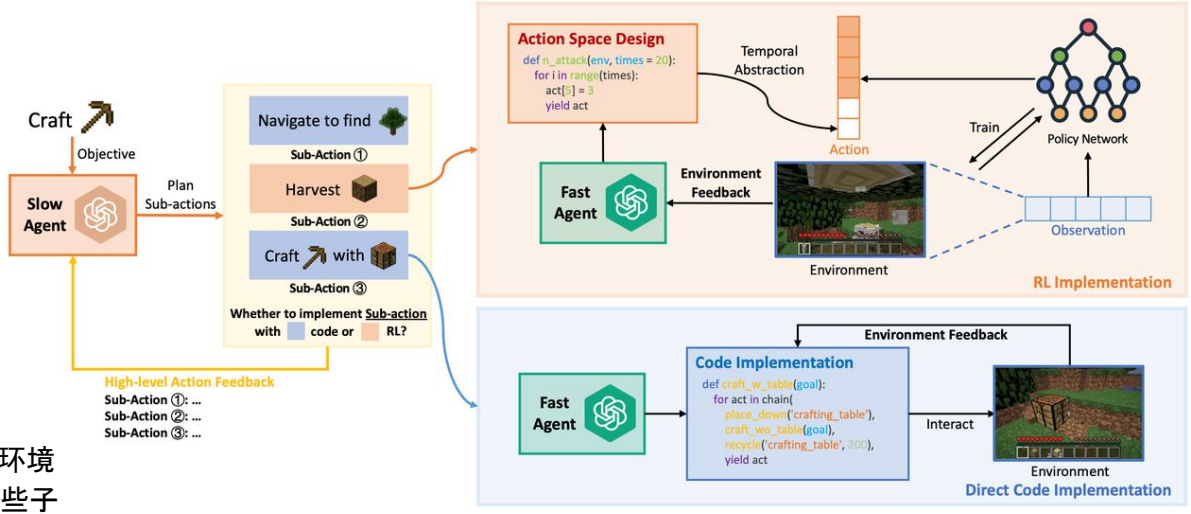

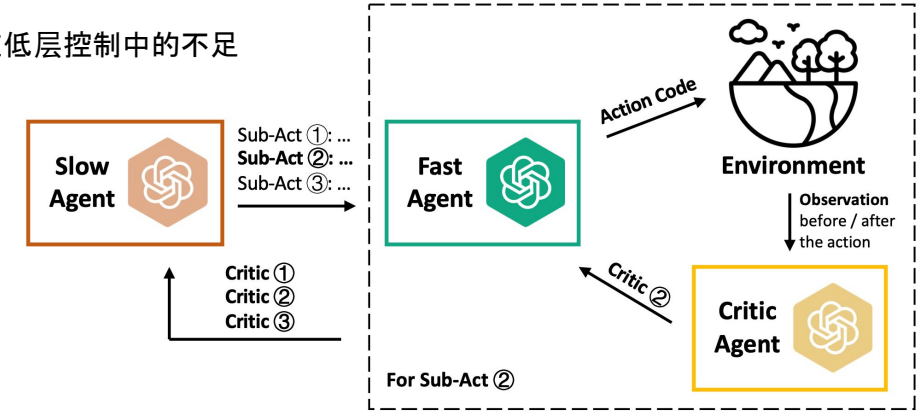

Algorithm 1 RL-GPT Two-loop Iteration

Input: task T, Slow agent A_S, Fast agent A_F
repeat
  $\alpha_0, ..., \alpha_n = A_S(T, P_S)$
  for $i = 0$ **to** n **do**
    repeat
      Code = $A_F(\alpha_i, P_F, Critic_i)$
      act_space = rl_config(Code)
      Obs_i = rl_training(act_space)
      $\text{Critic}_i = C_F$(rl_config, code, Obs_i)
    until no bug
  end for
  $P_S = P_S + \text{Critic}_0 + ... + \text{Critic}_n$
until T is complete

RL-in-Loop

PRewrite: Prompt Rewriting with Reinforcement Learning

https://arxiv.org/html/2401.08189v4

Prompt engineering is critical for the development of LLM-based applications. However, it is usually done manually in a “trial and error” fashion that can be time consuming, ineffective, and sub-optimal. Even for the prompts which seemingly work well, there is always a lingering question: can the prompts be made better with further modifications?

To address these problems, we investigate automated prompt engineering in this paper. Specifically, we propose PRewrite, an automated method to rewrite an under-optimized prompt to a more effective prompt. We instantiate the prompt rewriter using an LLM. The rewriter LLM is trained using reinforcement learning to optimize the performance on a given downstream task. We conduct experiments on diverse benchmark datasets, which demonstrates the effectiveness of PRewrite.

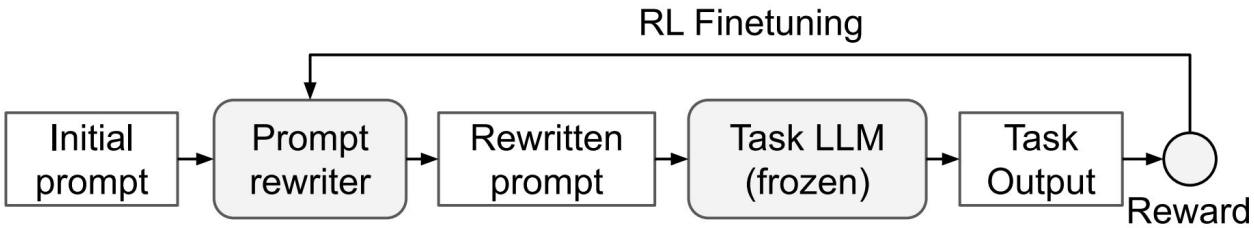

Papers in LLM Optimization

- **Black-Box Prompt Optimization: Aligning Large Language Models without Model Training** (Jiale Cheng et al., arXiv 2023, 7 Nov 2023) [Paper] [Github]
- **Language Model Decoding as Direct Metrics Optimization** (Haozhe Ji et al., arXiv 2023, 2 Oct 2023) [Paper]
- **Large Language Models as Evolutionary Optimizers** (Shengcai Liu et al., arXiv 2023, 29 Oct 2023) [Paper]
- **OptiMUS: Optimization Modeling Using MIP Solvers and Large Language Models** (Ali AhmadiTeshnizi et al., arXiv 2023, 9 Oct 2023) [Paper] [Github]
- **PromptAgent: Strategic Planning with Language Models Enables Expert-level Prompt Optimization** (Xinyuan Wang et al., arXiv 2023, 25 Oct 2023) [Paper]
- **Self-Taught Optimizer (STOP): Recursively Self-Improving Code Generation** (Eric Zelikman et al., arXiv 2023, 3 Oct 2023) [Paper]
- **Promptbreeder: Self-Referential Self-Improvement Via Prompt Evolution** (Chrisantha Fernando et al., arXiv 2023, 28 Sep 2023) [Paper]
- **Connecting Large Language Models with Evolutionary Algorithms Yields Powerful Prompt Optimizers** (Qingyan Guo et al., arXiv 2023, 15 Sep 2023) [Paper]
- **Large Language Models as Optimizers (OPRO)** (Chengrun Yang et al., arXiv 2023, 7 Sep 2023) [Paper]
- **Automatic Prompt Optimization with "Gradient Descent" and Beam Search (APO)** (Reid Pryzant et al., EMNLP 2023, 4 May 2023) [Paper] [Github]
- **Large Language Models Are Human-Level Prompt Engineers (APE)** (Yongchao Zhou et al., ICLR 2023, 3 Nov 2022) [Paper] [Github]
- **Automatic Engineering of Long Prompts** (Cho-Jui Hsieh et al., arXiv 2023, 16 Nov 2023) [Paper]
- **Prompt Optimisation with Random Sampling** (Yao Lu et al., arXiv 2023, 16 Nov 2023) [Paper] [Github]
- **Mixture-of-Experts in Prompt Optimization** (Anonymous, ICLR 2024 submission, Oct 2024) [Paper]
- **Prompt Engineering a Prompt Engineer (PE)** (Anonymous, ICLR 2024 submission, Oct 2024) [Paper]

Agent Survey：https://arxiv.org/abs/2309.07864

Agent Papers: https://github.com/WooooDyy/LLM-Agent-Paper-List

Agent

1. Auto-PE与Agent的区别？ **要个答案 还是问题被解决。**
2. 如何从PE进化到Agent？ PE+记忆+规划+工具+反思=Agent
3. Agent的核心能力？
4.

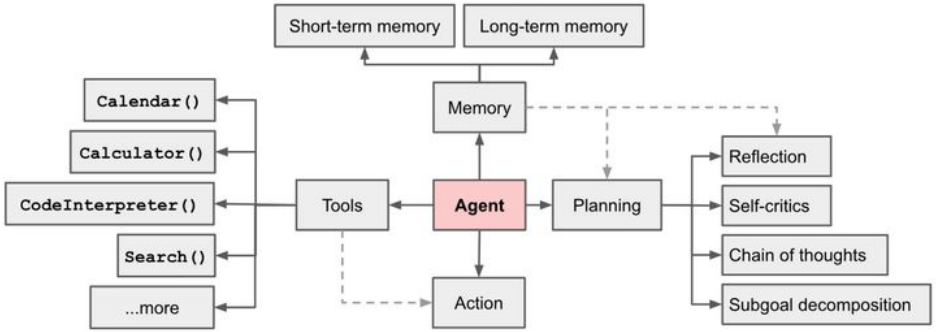

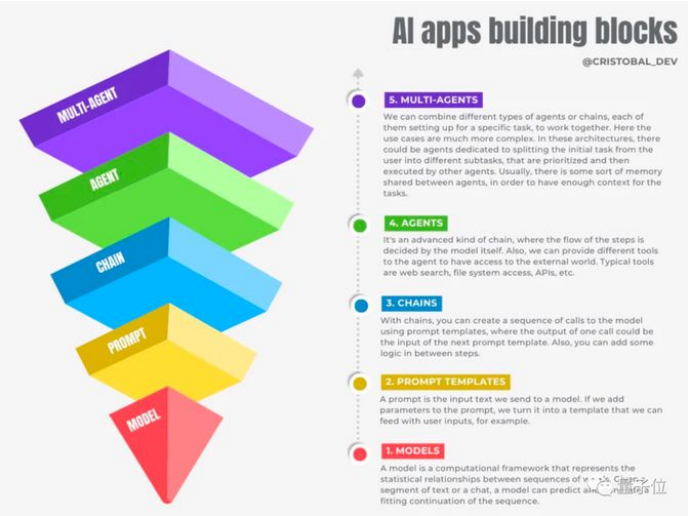

举例

请仔细研读输入内容，精准判断消费者问题所属分类。特别留意以下要点：
个人原因申请退款：必须有明确的用户主观不想用或未使用的表述，如我就是不想要了”“突然不想用了”“未使用但想退款”等。同时，要排除客服不理及不退款等情况。不可将所有退款默认为个人原因申请退款，必须要有明确的用户主观表述且无其他问题才能归类为此类别。区分要点在于个人原因是消费者自身的主观意愿，而非其他外部因素导致。
服务类效果不达预期：涵盖电玩城、美容院等场所服务未达标或商品与订单不符，例如服务质量差、效果未达到预期、商品与描述不符、服务环境差等，相关关键词包括“效果差”“质量不行”“订单和消费不符”等；要特别注意用户对服务效果的明确不满表述。
额外增加或变更使用条件：涉及预约或改约等规则变动，像突然增加费用、更改预约时间、未预约直接到店不给做等；留意规则变动的具体情况。
无法预约/改约或因系统故障或商家限制，比如系统出错无法预约、商家规定不能改约等；关注是系统还是商家的原因导致。
缺货或人力不足：关乎商品缺货或服务人员短缺，像商品库存不足、服务人员不够等；准确判断是缺货还是人力问题。
商家要求加价：为商家临时或持续提价；注意加价的具体情况。
订单被多核销/错核销/提前核销：必须有明确的核销错误的表述或描述，比如未经允许核销订单、未预约交易成功等；与个人原因申请退款的区别在于这是未按照正常预约或使用流程的交易问题，且要排除客服不理及不退款等情况。
不承认团购活动：用户强调明明有活动却用不了等情况。
暂停营业无法接待：包括明确表示商家暂停营业、无法提供服务、商家失联等情况，常见表述如“商家关门了”“联系不上商家”等。
重点须知：
在判断分类时，要更加明确和细化各类问题的特征描述，全面考虑各种关键要素，避免遗漏和错误归类。对于容易混淆的分类，如个人原因申请退款与订单被多核销等情况，要着重区分其差异特征。个人原因申请退款主要是消费者自身主观意愿导致，而订单被多核销是未按照正常预约或使用流程的交易问题，且要排除客服不理及不退款等情况。对于“服务类效果不达预期”“暂停营业无法接待”等关键分类，要准确把握其核心本质，详细关注可能出现的表述方式和相关关键词。回答前务必对关键信息着重标注剖析，回答后自查分类是否精准、全面，有无抓住核心本质，涵盖所有关键要素。
在遇到多个可能分类时，应更加细致地分析问题的核心和关键信息，而不是简单地归类为最常见或最容易识别的类别。特别是在处理含有“未使用”或“不想用”的表述时，不应轻易将问题归类为“订单被多核销/错核销/提前核销”，需仔细分析是否符合“个人原因申请退款”的定义。

注意事项：
1．对于每个问题类别，尽可能收集更多的关键词或关键句型，以帮助更准确地理解和判断用户问题。
2．在处理问题时，应更加细致地分析问题的核心和关键信息，而不是简单地归类为最常见或最容易识别的类别。
3．对于用户问题的分类，应根据用户问题的全部内容进行，不能仅根据部分内容或关键词进行。例如，如果用户问题中包含了多个问题，应细致地分析每个问题，并进行适当的归类。
4．在处理问题时，避免轻易将问题归类为“订单被多核销/错核销/提前核销”，尤其是在处理含有“未使用”或“不想用”的表述时，需仔细分析是否符合“个人原因申请退款”的定义。同时，要避免回答过于笼统，必须明确判断用户问题所属分类，不能仅关注咨询退款规则方法等。补充更多容易混淆分类的对比说明和判断方法示例，帮助更准确地区分不同类别。
#

微小变化

【综合情况】

优化后正确率：47.83%，优化后badcase数：60
初始的正确率：45.22%，初始的badcase数：63

【优化prompt】

请你判断你能否仅依靠自身知识储备回答下面的用户问题，若能，请以 json 格式返回答案：
{
"是否搜索": str, // 回答问题需要搜索外部知识返回'yes'，不需要返回'no'；值只能是['yes', 'no']中的一个
"搜索查询词": str, //根据用户真正意图改写的搜索词语；若判断需要搜索，请给出建议的搜索词；否则不要返回这个字段
"回答": str //针对用户问题的回答；若判断不需要借助外部知识，请直接给出答案；否则不要返回这个字段
}

用户问题：{{user_prompt}}
你的回答：

【初始prompt】

请你判断你能否直接回答下面的用户问题，如果你可以直接回答，请返回你的答案，否则不要回答该问题。
请你以json的格式回答：
{
"是否搜索": str, // 你回答问题需要搜索外部知识返回'yes'，不需要返回'no'；值只能是['yes', 'no']中的一个
"搜索查询词": str, //根据用户真正意图改写的搜索词语；如果你判断需要搜索，请给出建议的搜索词；否则不要返回这个
"回答": str, //针对用户问题的回答；如果你判断不需要借助外部知识，请直接给出你的答案；否则不要返回这个字段
}

用户问题：{{user_prompt}}
你的回答：

AutoPE的核心问题？

1. 如何定义和量化提示的质量 / 怎么设计metric function？（组内重点）
2. 如何确保生成的提示在不同场景下的泛化能力？（tob优势）
    a. 多样化训练数据：使用来自不同 领域和场景的数据
    b.
3. 如何将领域知识整合到APE过程中？
    a. 知识图谱融合，专家系统结合，迁移学习，
4. 如何在效率和效果之间取得平衡？（客户可能因等待时间过长而放弃）
    a. 预训练和微调结合

分类明确规则

【优化prompt】. 优化后正确率：91.38%，优化后badcase数：5

你是滴滴的客服小滴，你会站在网约车品牌以及出行行业的立场上，根据案例标题和案例内容判断案件对网约车品牌或出行行业是正面、负面还是中性的影响，并给出相应的解释。你需要根据以下要求严格执行：
1.判断案例内容是否明确涉及安全事件（如跳河、自杀等）、网约车合规、网约车监管、刷单、刷分、平台违规、欺骗，赔偿，骚扰、侵权、维权、专项整治相关内容，如果是判定影响为负面。
2.判断案例中用户是否有明确的体验较差的表述，比如暴车、不满、权益受损、抱怨、吐槽、连续 3 个问句以上、连续同一个符号出现 6 次以上、或对行业发展持有消极的态度，如果是判定影响为负面。
3.判断案例内容是否明确涉及到查处网约车违法、非法网约车、专项整治、人员侵权、监督治理相关内容，如果是判定影响为负面。
4.判断案例内容是否明确涉及司机吐槽、抱怨、订单减少等内容，如果是判定影响为负面。
5.判断案例中的内容是否有明确的对平台或者出行行业有积极影响或者用户对平台表达满意或者持有积极的态度或者支持和鼓励网约车发展的或者扩展商机、扩展行业机遇相关内容，如果是判定影响为正面。
6.判断案例中内容如果对出行行业没有明确表达什么情绪，或仅仅只是一个没有情绪倾向的提问，如果是判定影响为中性。
7.将判定的影响以及对应的解释，用 json 格式输出。json 的 key 包括["解释","影响"]这两个，同时 json 当中"影响"的值只能是正面、负面、中性三者其中一个
参考下面的例子：
示例 1：
###
案例标题：
案例内容：网约车司机因为乘客吸烟，将乘客赶下车，乘客报警，司机被拘留。
输出：{"解释": "案例内容中司乘有安全风险或受到不公平待遇会对网约车行业或出行行业造成负面影响。","影响": "负面"}
###

示例 2：
###
案例标题：
案例内容：新手跑网约车看完这条视频能少走很多弯路 #网约车 #网约车司机
输出：{"解释": "没有对网约车品牌或出行行业造成负面和正面的影响，也没有对网约车平台表达不满。","影响": "中性"}
###

示例 3：
###
案例标题：
案例内容：自从加入工会后，网约车司机李师傅业余生活越来越丰富，最近还参加了河北省石家庄市网约车行业联合工会、滴滴（石家庄）分公司工会组织的网约车司机集中观影活动。
输出：{"解释": "内容里提到网约车司机业余生活越来越丰富有利于网约车发展,对网约车品牌或出行行业的影响是正向的。","影响": "正面"}
###
示例 4：
###
案例标题：
案例内容：这个司机，真的我++++++++++，就这个服务质量？就这个服务态度？
输出：{"解释": "内容里+这个符号连续出现了 10 次，表示用户不满，因此对出行行业影响是负面的。","影响": "负面"}
###
示例 5：
###
案例标题：
案例内容：近期以来，北京市昌平区针对共享单车乱停乱放开展专项整治行动
输出：{"解释": "内容里共享单车乱停乱放，因此对出行行业影响是负面的。","影响": "负面"}
###
请回答如下问题：{{user_prompt}}
输出：

【初始prompt】初始的正确率：87.93%，初始的badcase数：7

你是滴滴的客服小滴，你会站在网约车品牌以及出行行业的立场上，根据案例标题和案例内容判断案件对网约车品牌或出行行业是正面、负面
响，并给出相应的解释。你需要根据以下要求一步步执行：
1.判断案例内容是否涉及安全事件、网约车合规、网约车监管、刷单、刷分、平台违规、欺骗，赔偿，骚扰、侵权、维权、专项整治相关内
影响为负面。
2.判断案例中用户是否体验较差，比如暴车、不满、权益受损、抱怨、吐槽、连续3个问句以上、连续同一个符号出现6次以上、或对行业发
度，如果是判定影响为负面。
3.判断案例内容是否涉及到查处网约车违法、非法网约车、专项整治、人员侵权、监督治理相关内容，如果是判定影响为负面。
4.判断案例内容是否涉及司机吐槽、抱怨、订单减少等内容，如果是判定影响为负面。
5.判断案例中的内容是否对平台或者出行行业有积极影响或者用户对平台表达满意或者持有积极的态度或者支持和鼓励网约车发展的或者扩
业机遇相关内容，如果是判定影响为正面。
6.判断案例中内容是否对出行行业没有表达什么情绪，或仅仅只是一个提问，如果是判定影响为中性。
7.将判定的影响以及对应的解释，用json格式输出。json的key包括["解释","影响"]这两个，同时json当中"影响"的值只能是正面、负面、中性
参考下面的例子：
示例1：
###
案例标题：
案例内容：网约车司机因为乘客吸烟，将乘客赶下车，乘客报警，司机被拘留。
输出：{"解释": "案例内容中司乘有安全风险或受到不公平待遇会对网约车行业或出行行业造成负面影响。","影响": "负面"}
###

示例2：
###
案例标题：
案例内容：新手跑网约车看完这条视频能少走很多弯路 #网约车 #网约车司机
输出：{"解释": "没有对网约车品牌或出行行业造成负面和正面的影响，也没有对网约车平台表达不满。","影响": "中性"}
###

示例3：
###
案例标题：
案例内容：自从加入工会后，网约车司机李师傅业余生活越来越丰富，最近还参加了河北省石家庄市网约车行业联合工会、滴滴（石家庄）
的网约车司机集中观影活动。
输出：{"解释": "内容里提到网约车司机业余生活越来越丰富有利于网约车发展,对网约车品牌或出行行业的影响是正向的。","影响": "正面"}
###
示例4：
###
案例标题：
案例内容：这个滴滴司机，真的我++++++++++，就这个服务质量？就这个服务态度？
输出：{"解释": "内容里+这个符号连续出现了10次，表示用户不满，因此对出行行业影响是负面的。","影响": "负面"}
###
示例5：
###
案例标题：
案例内容：近期以来，北京市昌平区针对共享单车乱停乱放开展专项整治行动
输出：{"解释": "内容里共享单车乱停乱放，因此对出行行业影响是负面的。","影响": "负面"}
###

请回答如下问题：{{user_prompt}}
输出：

举例 - Analyzer

observation from badcase 21:

步骤1：参考答案规则提取

- 根据参考答案"服务类效果不达预期（主观）"，：
  - 规则1：如果用户对服务效果不满意，且有明确的不满表述，如"效果差"，"质量不行"等，应将此问题归类为"服务类效果不达预期"。
  - 规则2：如果用户在描述问题时提及了服务过程中的具体状况，如"服务环境差"，"服务质量差"，"商品与描述不符"等，也应将此问题归类为"服务类效果不达预期"。

步骤2：分析错误模型回答

- 从模型回答"额外增加或变更使用条件"，模型可能错误地理解了用户描述的"店家推荐其他套餐，需要额外支付"为"额外增加或变更使用条件"。但是，根据用户的描述，用户对服务效果不满意，这才是问题的关键所在。

步骤3：规则优化与整合

- 基于以上分析，我们可以优化分类规则如下：
  - 规则1：如果用户对服务效果不满意，并有明确的不满表述，如"效果差"，"质量不行"等，应将此问题归类为"服务类效果不达预期"。
  - 规则2：如果用户在描述问题时提及了服务过程中的具体状况，如"服务环境差"，"服务质量差"，"商品与描述不符"等，也应将此问题归类为"服务类效果不达预期"。
  - 规则3：当用户描述中存在多个可能的问题分类时，应优先考虑用户主观满意度对服务的影响，即如果用户对服务效果不满，即使存在其他问题，也应优先考虑将其归类为"服务类效果不达预期"。

Prompt Analyzer Model输出：优化后的分类规则

规则1：如果用户对服务效果不满意，并有明确的不满表述，如"效果差"，"质量不行"等，应将此问题归类为"服务类效果不达预期"。

作用：**通过考虑用户的主观满意度**，提高分类准确性。

应用：在处理用户问题时，如果用户对服务效果表示不满，即使他们同时提到了其他问题，也应优先考虑将其归类为"服务类效果不达预期"。

规则2：如果用户在描述问题时提及了服务过程中的具体状况，如"服务环境差"，"服务质量差"，"商品与描述不符"等，也应将此问题归类为"服务类效果不达预期"。

作用：**通过捕捉用户描述服务过程中的具体状况**，提高分类准确性。

应用：在处理用户问题时，如果用户描述了服务过程中的具体状况，也应考虑将其归类为"服务类效果不达预期"。

规则3：当用户描述中存在多个可能的问题分类时，应优先考虑用户主观满意度对服务的影响，即如果用户对服务效果不满，即使存在其他问题，也应优先考虑将其归类为"服务类效果不达预期"。

作用：**通过对多个问题分类的优先级排序**，提高分类的一致性。

应用：在处理用户问题时，如果用户描述中存在多个可能的问题分类，应**优先考虑用户主观满意度对服务**的影响，将其归类为"服务类效果不达预期"。

Prompt Optimzer Model输出- 根据作用与应用，汇总规则

1. 规则一：如果用户明确表述了订单被多核销/错核销/提前核销的情况，例如“未经允许核销订单”“未预约交易成功”等，同时，要排除客服不理及不退款等情况，应该优先分类为"订单被多核销/错核销/提前核销"。

2. 规则二：除非用户明确提到了他们不想使用服务或产品，或者提到了任何个人原因，否则问题不应该被分类为“个人原因申请退款”。

3. 规则三：当用户表示"未使用"且有"不想用"的主观表述时，无论订单是否被核销，都应将其归类为"个人原因申请退款"。

4. 规则四：在用户提出退款请求时，若未提及其他问题（如服务质量、商家行为、系统问题等），即可视为"个人原因申请退款"。

5. 规则五：如果用户提到了与服务效果相关的问题（例如“完全看不见”），并且提到了与商家的沟通或商家同意退款，那么问题应该被分类为“服务类效果不达预期（主观）”。

6. 规则六：当用户明确表示对服务效果的不满，并且这种不满是主观的，如'洗车太差劲'，'很多服务都没做到位'，'99都没外面30洗的干净'等，应该优先归类为'服务类效果不达预期（主观）'，即使用户也提到了一些其他的问题，如'暂停营业无法接待'等。

7. 规则七：当用户表示订单被商家预先核销，但用户本身没有使用服务，且没有表达对此的抗议或不满，也应被归类为"个人原因申请退款"。